RETO AVANZADO 1 - MERCEDES BENZ

Grupo: Cibercolegas
Nombres: Noa Ramos Ruiz, Javier Romeo Enríquez de Salamanca, Mario Cáceres Morales, Noelia Sánchez Vilchez

A. Planteamiento

El objetivo es comprobar si K-Means es el algoritmo más adecuado para segmentar a los clientes, comparándolo con otros algoritmos entrenados con **el mismo número de grupos (k = 6)** y **los mismos datos preparados**: la matriz del reto 2 con **173.456 clientes y 18 columnas** codificadas y escaladas. Así, cualquier diferencia se debe al algoritmo y no a los datos.

Algoritmo	Cómo agrupa a los clientes	Configuración probada
K-Means (referencia)	Asigna cada cliente al centro más cercano; busca grupos compactos.	k = 6, n_init=10, random_state=42
Gaussian Mixture (GMM)	Supone que los clientes proceden de 6 distribuciones normales y estima la probabilidad de pertenecer a cada una.	Covarianza completa (full) y diagonal (diag)
Agglomerative Clustering	Parte de cada cliente como un grupo y une los más parecidos hasta quedarse con 6.	Criterios ward y average
DBSCAN (contraste)	Agrupa zonas densas y marca como ruido a los clientes aislados; no admite fijar k.	Radio eps elegido con el gráfico de k-distancias

- **Métricas:** silueta (mayor es mejor), Davies-Bouldin (menor es mejor), Calinski-Harabasz (mayor es mejor) y tamaño del grupo menor y mayor, que indica si los segmentos son utilizables para marketing. La silueta de todos los algoritmos se mide sobre **las mismas 3 muestras de 20.000 clientes**, para que la comparación sea justa.
- **Limitación del clustering aglomerativo:** necesita la distancia entre todos los pares de clientes (más de 100 GB de memoria con 173.456). Se entrenó con una muestra de 15.000 clientes y el resto se asignó al grupo de su cliente más parecido. Como **control**, se entrenó también K-Means con esa misma muestra, para separar el efecto del algoritmo del de la muestra.

B. Tabla y gráfico comparativo de métricas

Algoritmo	Silueta	Davies-Bouldin	Calinski-Harabasz	Grupo menor	Grupo mayor
K-Means	0,110	1,963	16.976	12,4 %	19,3 %
K-Means (misma muestra)	0,102	2,007	16.227	12,6 %	19,0 %
GMM (full)	0,086	3,067	8.759	3,3 %	45,4 %
GMM (diag)	0,096	2,691	8.530	2,1 %	45,4 %
Agglomerative (ward)	0,075	2,679	10.409	9,0 %	28,0 %
Agglomerative (average)	0,052	1,833	1.063	0,0 %	97,0 %

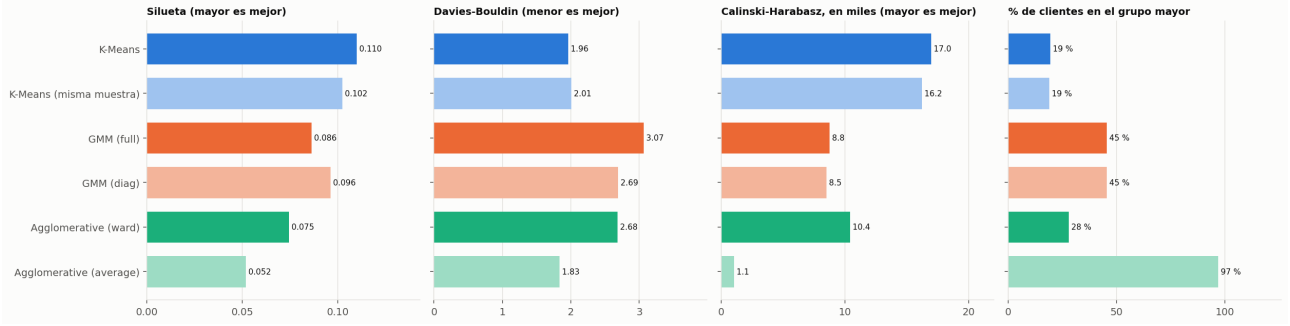


Figura 1. Comparativa de métricas con k = 6 y los mismos datos.

- **K-Means obtiene la mejor silueta (0,110) y el mejor Calinski-Harabasz (16.976)**, con segmentos equilibrados (entre el 12,4 % y el 19,3 % de los clientes).
- **Davies-Bouldin:** el valor más bajo es el de Agglomerative con average (1,833), pero es un espejismo: ese índice premia que los grupos estén lejos entre sí, y average deja al 97 % de los clientes en un único grupo y crea cinco grupos diminutos de clientes extremos. Entre las segmentaciones utilizables, K-Means es también el mejor.

- **El control confirma la comparación:** K-Means entrenado con la misma muestra que el aglomerativo mantiene una silueta de 0,102, muy superior a la de Ward (0,075). La diferencia se debe al algoritmo, no a la muestra.

C. Análisis de cada algoritmo alternativo

Gaussian Mixture Models

El GMM obtiene peor silueta (0,086 con covarianza completa y 0,096 con diagonal), concentra el 45 % de los clientes en un solo grupo y asigna a todos los clientes con una probabilidad prácticamente igual a 1. Al revisar la composición de sus componentes se ve el motivo: **cada una reúne a clientes con la misma situación de financiación**, y varias también con la misma motorización:

Componente	% clientes	Situación de financiación	Motorización predominante
0	17,3 %	Financiación activa (100 %)	Combustión 60 % · Mild hybrid 33 %
1	45,4 %	Nunca ha financiado (100 %)	Combustión 85 %
2	11,7 %	Nunca ha financiado (100 %)	Mild hybrid 100 %
3	13,5 %	Nunca ha financiado (100 %)	Híbrido enchufable 55 % · Eléctrico 45 %
4	8,9 %	Financiación activa (100 %)	Híbrido enchufable 38 % · Eléctrico 38 %
5	3,3 %	Financió en el pasado (100 %)	Combustión 50 %

La razón es matemática: el GMM supone datos **continuos y gaussianos**. Cuando un grupo tiene una columna 0/1 constante (por ejemplo, todos nunca han financiado), su varianza en esa columna es cero y la densidad se dispara, así que al modelo le compensa separar por las columnas binarias en lugar de por el perfil completo del cliente. **El GMM no es adecuado para datos con muchas variables categóricas codificadas en one-hot**, como los nuestros.

Agglomerative Clustering

Con el criterio **ward** (el más parecido a K-Means) produce grupos utilizables, aunque menos equilibrados (del 9 % al 28 % de los clientes) y con una silueta claramente inferior. Con **average** degenera: los clientes con valores extremos forman grupos de muy pocas personas y el resto queda junto. Además, solo puede entrenarse con una muestra, lo que lo hace poco práctico para una base de este tamaño.

DBSCAN

DBSCAN no permite fijar k = 6: el número de grupos lo decide el radio de vecindad (eps). Se probaron cuatro radios elegidos a partir del gráfico de k-distancias:

eps	Percentil	Nº de grupos	% de ruido	% en el grupo mayor
1,22	70	13	9,8 %	38,5 %
1,34	80	12	6,2 %	38,7 %
1,53	90	1	1,6 %	98,4 %
1,67	95	1	0,5 %	99,5 %

Con radios pequeños aparecen muchos grupos y una parte de los clientes queda como ruido, sin segmento; en cuanto el radio crece, casi todos se funden en un único grupo. Es lo esperable en una base de clientes que forma un **continuo** sin zonas densas separadas por huecos. DBSCAN queda descartado.

D. ¿Cambian los segmentos entre algoritmos?

Para saber si los algoritmos encuentran los mismos segmentos, aunque los numeren distinto, se usan dos medidas de coincidencia: el **ARI** (1 si dos segmentaciones son idénticas, 0 si coinciden lo mismo que por azar) y la **NMI** (de 0 a 1, información compartida entre ambas).

Algoritmo	ARI frente a K-Means	NMI frente a K-Means
K-Means (misma muestra)	0,792	0,757
GMM (full)	0,159	0,258
GMM (diag)	0,198	0,265
Agglomerative (ward)	0,219	0,294
Agglomerative (average)	0,003	0,030

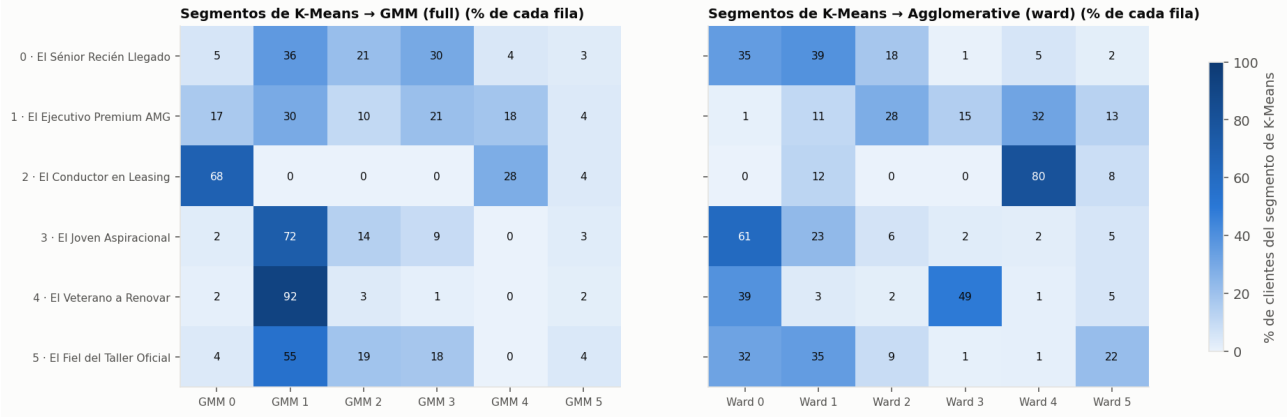


Figura 2. A dónde van los clientes de cada segmento de K-Means en GMM y en Ward (% de cada fila).

- **Sí, los segmentos cambian de forma significativa:** la coincidencia con K-Means es baja en todos los algoritmos alternativos (ARI de 0,16 en GMM y 0,22 en Ward), y los clientes de casi todos los segmentos se reparten entre varios grupos de los otros algoritmos.
- **El GMM reorganiza a los clientes por financiación y motorización** y mezcla perfiles muy distintos; **Ward** se parece algo más a K-Means, pero traza las fronteras en otros puntos, algo esperable cuando los clientes forman un continuo.
- **La excepción es el Conductor en Leasing**, que se mantiene reconocible en ambos algoritmos porque se define por una variable muy marcada: la financiación activa.
- **K-Means es consistente consigo mismo:** entrenado con una muestra reproduce sus propios segmentos (ARI 0,79), mucho más que cualquier otro algoritmo. El reto avanzado 3 lo confirma con 20 submuestras.

E. Conclusión: algoritmo más adecuado

K-Means es el algoritmo más adecuado para esta segmentación, por cinco motivos:

- **Mejor calidad de los grupos:** la mejor silueta y el mejor Calinski-Harabasz de todos los algoritmos comparados con k = 6, y el mejor Davies-Bouldin entre las segmentaciones utilizables.
- **Segmentos equilibrados y accionables:** entre el 12,4 % y el 19,3 % de los clientes por segmento, frente al 45 % en un solo grupo del GMM o el 97 % de Agglomerative average.
- **Coherente con los datos:** trabaja con distancias y aprovecha todas las variables a la vez, mientras que el GMM se desvía hacia las columnas binarias.
- **Escalable:** se entrena con los 173.456 clientes en segundos; Agglomerative no cabe en memoria y DBSCAN ni siquiera permite fijar el número de segmentos.
- **Interpretable y reproducible:** cada segmento tiene un centro que resume a su cliente tipo y, con una semilla fija, el resultado es siempre el mismo.

Matiz: todas las siluetas son bajas, también la de K-Means, porque los clientes forman un continuo de perfiles. Los segmentos deben interpretarse como perfiles tipo útiles para orientar acciones comerciales, no como grupos aislados.