RETO 2 AVANZADO - MERCEDES BENZ

Grupo: Cibercolegas
Nombres: Noa Ramos Ruiz, Javier Romeo Enríquez de Salamanca, Mario Cáceres Morales, Noelia Sánchez Vilchez

A. Planteamiento

El objetivo es resumir el perfil de cada cliente en dos o tres ejes (componentes principales) para poder **visualizar los segmentos** obtenidos con K-Means (k = 6). Partiendo del CSV original se limpiaron los datos, se agregaron a una fila por cliente (**173.456 clientes**) y se construyeron las features derivadas del reto 2. Después se aplicó el PCA sobre **12 features de negocio**, seleccionadas para evitar redundancias:

Feature descartada	Muy correlacionada con	Correlación
itvs_passed_count	main_vehicle_age_years	0,86
warranty_visits_total	warranty_visit_frequency	0,93
currently_connected_vehicles	digital_engagement_index	0,96

- **Por qué se descartan:** dos variables casi iguales contarían dos veces en el PCA y desplazarían los ejes hacia lo que miden. Las tres descartadas son redundantes por construcción (las inspecciones se calculan con la antigüedad del coche, el total de visitas es la base de su frecuencia y los vehículos conectados forman parte del índice digital).
- **Preparación:** imputación por mediana, *log1p* en las cuatro variables con cola larga (frecuencia de visitas, índice digital, poder adquisitivo y vehículos del historial) y *StandardScaler* en todas las continuas. El escalado es imprescindible: el PCA busca las direcciones de mayor varianza y, sin él, el poder adquisitivo (en euros) acapararía toda la varianza solo por sus unidades. Las binarias se mantienen en 0/1.
- **Modelo:** PCA de scikit-learn con *n_components=3* y *random_state=42*.

B. Varianza explicada por cada componente

Componente	Varianza explicada	Varianza acumulada
PC1	22,5 %	22,5 %
PC2	16,7 %	39,2 % (plano 2D)
PC3	12,5 %	51,7 % (espacio 3D)

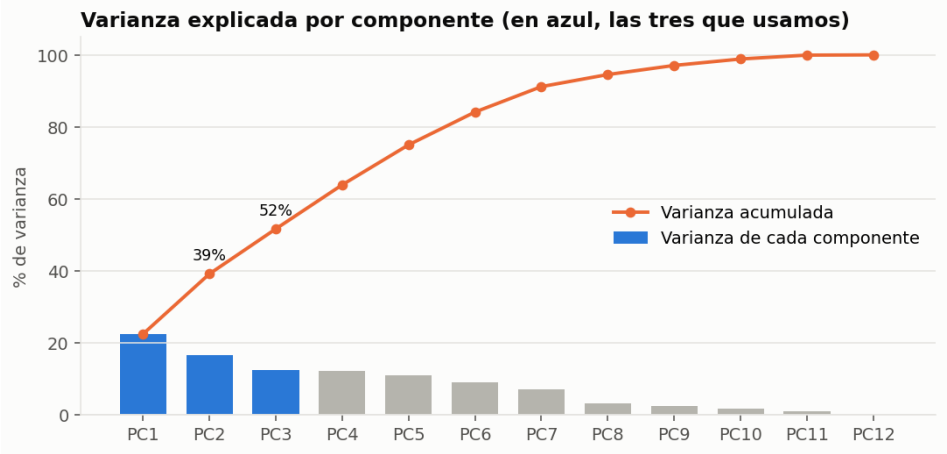


Figura 1. Varianza explicada por componente (en azul, las tres utilizadas).

El plano 2D conserva el **39,2 %** de la información y el espacio 3D el **51,7 %**; harían falta 6 de las 12 componentes para superar el 80 %. Es razonable para **visualizar**: los clientes se describen con muchas dimensiones poco correlacionadas entre sí, así que ningún par de ejes puede resumirlas todas. Los gráficos muestran tendencias generales, no todas las diferencias entre clientes.

C. Interpretación de las componentes principales

Los **loadings** son el peso de cada variable original en cada componente: un valor alto, positivo o negativo, indica que la variable define el eje, y el signo, en qué dirección. En negrita, los pesos de 0,30 o más en valor absoluto.

Variable original	PC1	PC2	PC3
tenure_years	**0,53**	**0,30**	**0,34**
n_vehicles_history	**0,48**	**-0,41**	0,07
digital_engagement_index	**0,46**	**-0,34**	0,11
warranty_visit_frequency	**0,41**	**0,52**	-0,10
main_vehicle_age_years	-0,21	**0,42**	**0,61**
purchasing_power_per_household_eur	0,15	**0,41**	**-0,50**
finance_active	0,09	-0,04	-0,09
has_telemetry	0,09	0,01	0,05
main_segment_tier	0,09	-0,00	0,06
age_ord	0,05	0,09	**-0,48**
main_is_van	0,02	-0,04	-0,02
is_b2b	0,00	-0,01	0,00

- **PC1 · Profundidad de la relación con la marca.** Pesan en positivo la antigüedad como cliente, los vehículos del historial, el índice digital y la frecuencia de visitas al taller. A la derecha están los clientes veteranos, con varios coches, conectados y que usan la posventa; a la izquierda, los recién llegados con un solo vehículo.
- **PC2 · Cliente maduro de posventa frente a cliente multivehículo.** Pesan en positivo las visitas al taller, la antigüedad del coche y el poder adquisitivo, y en negativo los vehículos del historial y el índice digital.
- **PC3 · Coche antiguo en manos de clientes jóvenes.** Pesa en positivo la antigüedad del vehículo y en negativo la edad del cliente y el poder adquisitivo.
- **Las variables binarias** (furgoneta, telemetría, B2B, financiación) apenas pesan: al mantenerlas en 0/1 su varianza es mucho menor que la de las continuas estandarizadas. Es buscado: evita que una característica minoritaria, como B2B, domine la proyección.

D. Visualización de los clusters

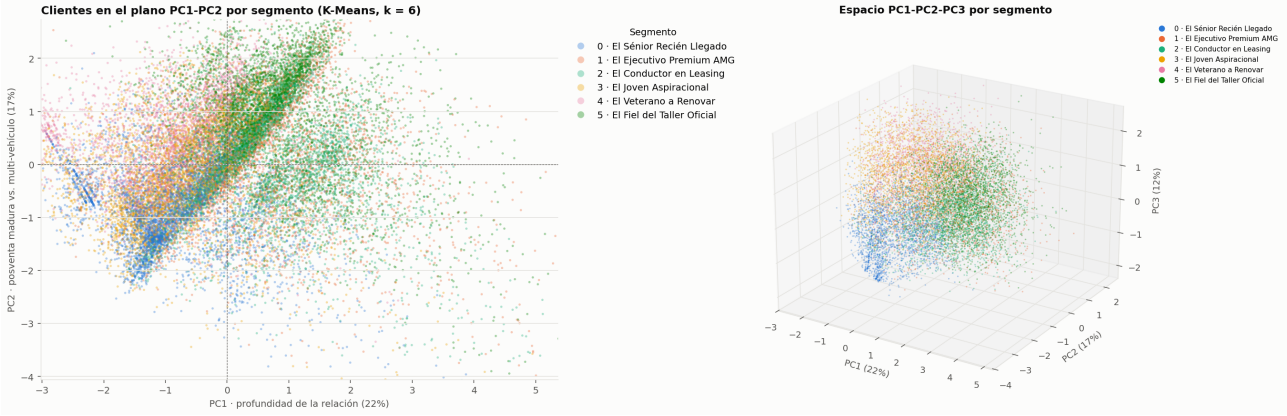


Figura 2. Clientes coloreados por segmento en el plano PC1-PC2 (izquierda, muestra de 25.000 clientes) y en el espacio PC1-PC2-PC3 (derecha).

Para leer mejor los gráficos se calculó la **posición media de cada segmento** y se cruzó con indicadores de valor de sus clientes (no se dispone de datos de facturación, así que son la mejor aproximación al valor de cada perfil):

Segmento	PC1	PC2	% clientes	Poder adq. (k€)	% usa el taller	Meses cliente
El Sénior Recién Llegado	-0,87	-0,91	16,9 %	89	41 %	15
El Ejecutivo Premium AMG	0,68	0,06	15,1 %	113	87 %	39
El Conductor en Leasing	0,63	-0,12	18,4 %	115	91 %	37
El Joven Aspiracional	-0,76	-0,29	17,8 %	93	55 %	27
El Veterano a Renovar	-0,91	0,47	12,4 %	100	45 %	31
El Fiel del Taller Oficial	0,92	0,84	19,3 %	119	97 %	52

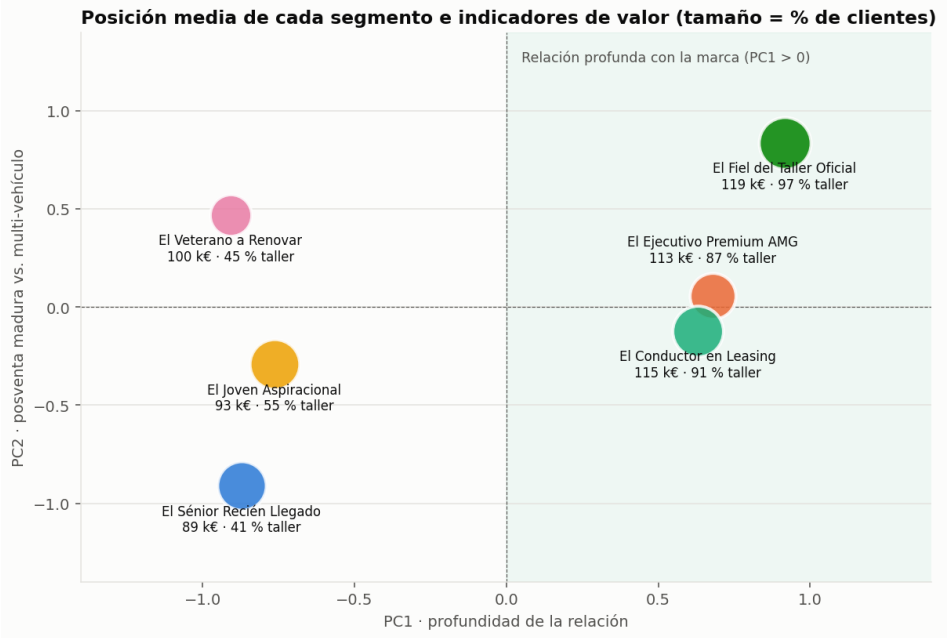


Figura 3. Posición media de cada segmento e indicadores de valor.

- **La mitad derecha (PC1 > 0) es la zona de mayor valor:** El Ejecutivo Premium AMG, El Conductor en Leasing, El Fiel del Taller Oficial. Son los segmentos con mayor poder adquisitivo (113-119 k€) y con casi todos sus clientes usando el taller oficial (87-97 %). Suman el 53 % de la base.
- **La esquina superior derecha es la del cliente más rentable para la posventa:** el Fiel del Taller Oficial combina la relación más larga, el mayor poder adquisitivo y el uso más intenso del taller.
- **La mitad izquierda (PC1 < 0) es la zona de oportunidad y de riesgo:** El Sénior Recién Llegado, El Joven Aspiracional, El Veterano a Renovar, con menos poder adquisitivo (89-100 k€) y un uso del taller oficial mucho menor (41-55 %).

E. Valoración: ¿los clusters son visualmente separables?

No de forma nítida. En el plano del PCA las nubes de los segmentos se solapan en sus bordes, y la medida objetiva lo confirma: la silueta de los clústeres en el espacio del PCA es de **-0,051** en 2D y de **-0,003** en 3D (valores cercanos a 0 indican grupos solapados). Sí se distinguen claramente sus **posiciones medias**, que caen en zonas distintas del plano y encajan con los perfiles del reto 4.

Hay dos motivos para el solapamiento:

- **Los ejes solo recogen parte de la información** (39 % en 2D y 52 % en 3D).
- **K-Means se entrenó con variables que este PCA no incluye o apenas pondera**, como el tipo de financiación y la motorización en one-hot. Por ejemplo, el Conductor en Leasing se define sobre todo por la financiación activa, una variable binaria con poco peso en estos ejes.

Conclusión: la segmentación captura diferencias reales de perfil, visibles en la posición de cada segmento, pero entre clientes que forman un **continuo**. Los segmentos son útiles para orientar acciones de marketing, no grupos aislados con fronteras nítidas; es coherente con la silueta moderada del reto 3 y con la estabilidad comprobada en el reto avanzado 3.