RETO 2 - MERCEDES BENZ

Grupo: Cibercolegas
Nombres: Noa Ramos Ruiz, Javier Romeo Enríquez de Salamanca, Mario Cáceres Morales, Noelia Sánchez Vilchez

A. Tratamiento de nulos y limpieza de datos

A partir de las conclusiones del análisis exploratorio (reto 1) se eliminaron las columnas sin valor analítico directo (índice exportado, identificadores, modas concatenadas, contadores técnicos y telemetría en bruto) y el resto de nulos se trató según la naturaleza de cada columna:

Columna	% nulos	Tratamiento
model_class	1,1 %	Deducida del nombre comercial del vehículo (exacto o por prefijo).
engine_concept	44,4 %	Cascada de reglas validadas (nombres EQ = eléctrico, sufijo e/de = híbrido enchufable, mismo modelo y año...). Sin evidencia, queda como desconocido: nunca se supone combustión.
fuel_type	59,0 %	Reglas validadas a partir del motor ya tratado y del nombre (diésel).
date_of_first_registration	1,4 %	Mediana de la fecha de los vehículos de la misma serie; las imputadas quedan marcadas.
gender_derived	11,2 %	Categoría desconocido: dato inferido y nulos no aleatorios.
Poder adquisitivo y población	6,3 %	Mediana del país (Suiza o Austria), con indicador *socio_imputed*.
Telemetría	61,4 %	No se imputa: se resume en el indicador binario *has_telemetry*.

Las reglas de deducción se validaron ocultando valores conocidos: cuando deciden, aciertan prácticamente siempre (precisiones superiores al 95 %), y los casos sin evidencia se dejan como desconocidos (9,6 % de los vehículos principales en el caso del motor).

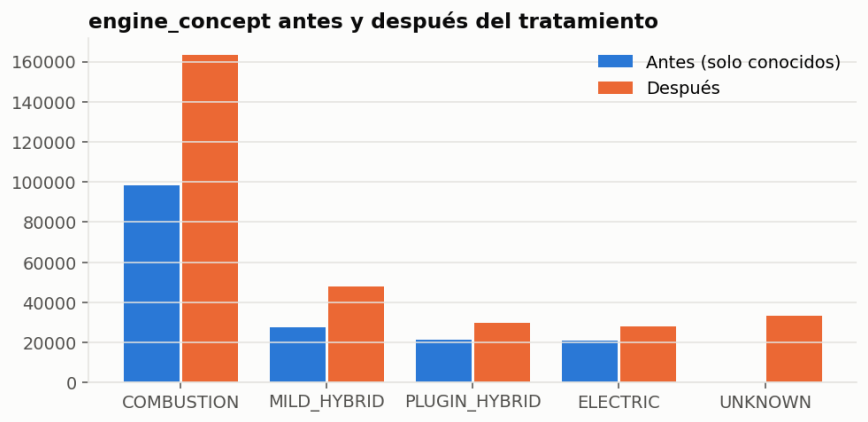


Figura 1. Motorización antes y después del tratamiento de nulos.

B. Agregación a una fila por cliente

Para segmentar personas, la tabla se estructuró a nivel de cliente único (**173.456 clientes**):

- **Vehículo principal:** el vehículo actual matriculado más recientemente (o el más reciente del historial si el cliente no tiene ninguno activo).
- **Consolidación del historial:** número de vehículos distintos (*n_vehicles_history*), visitas acumuladas al taller en garantía (*workshop_visits_total*), pertenencia a flotas o empresas (*is_b2b*) y conectividad.

C. Construcción de features derivadas

Feature	Qué mide	Columnas de origen
main_vehicle_age_years	Años desde la matriculación del vehículo principal: ventana de renovación	date_of_first_registration
tenure_years	Años como cliente de Mercedes-Benz	months_as_mb_customer
itvs_passed_count	Inspecciones técnicas superadas según el calendario de Suiza o Austria	Antigüedad del vehículo, country_code

Feature	Qué mide	Columnas de origen
warranty_visit_frequency	Visitas al taller en garantía por vehículo del historial	workshop_visits_warranty_goodwill , vehicle_id
has_telemetry	1 si algún vehículo del cliente envía datos de conducción	Columnas de telemetría (presencia)
urban_density_classification	Personas por hogar del código postal	population, number_of_households
digital_engagement_index	Vehículos conectados + aceptación del canal digital	currently_connected_vehicles, consent_epost
main_is_van	1 si el vehículo principal es comercial (Sprinter, Vito, Citan)	product_group

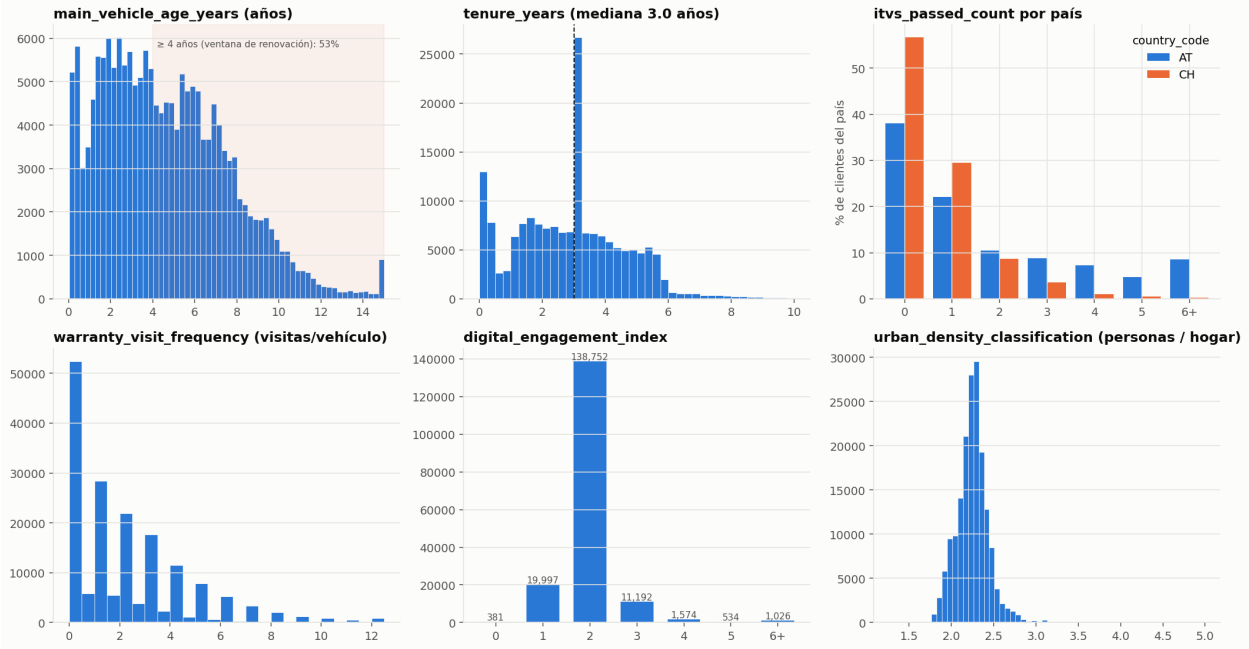


Figura 2. Distribución de las features derivadas.

¿Por qué estas variables derivadas?

No es una selección improvisada: cada variable responde a una pregunta de negocio concreta.

Pregunta de negocio	Variables	Para qué sirve
¿Cuándo ofrecerle un coche nuevo? (ciclo de vida)	main_vehicle_age_years, itvs_passed_count	Detectar la fase del vehículo: con más de 4 años entra en la ventana de recompra.
¿Cómo se relaciona con el taller? (posventa)	warranty_visit_frequency	Distinguir al cliente que apenas pisa el taller del que requiere atención constante.
¿Es digital o tradicional? (digitalización)	has_telemetry, digital_engagement_index	Separar al cliente hiperconectado del analógico sin imputar la telemetría que falta.
¿Qué uso le da al vehículo? (particular o comercial)	main_is_van, urban_density_classification	Aislar el uso profesional o de furgoneta y describir el entorno del cliente.

D. Selección justificada de features para el modelo

Se seleccionaron 11 variables de alto valor comercial, con pocos nulos y sin redundancias entre ellas:

Feature	Origen	Codificación	Para qué sirve
main_vehicle_age_years	derivada	numérica · RobustScaler	Ventana de renovación
tenure_years	derivada	numérica · RobustScaler	Lealtad y ciclo de vida
warranty_visit_frequency	derivada	log1p · RobustScaler	Uso de posventa
digital_engagement_index	derivada	log1p · RobustScaler	Conectividad y canal digital
purchasing_power_per_household_eur	base	log1p · RobustScaler	Capacidad de compra de la zona
age_range	base	ordinal 0-5 · RobustScaler	Etapa vital
main_model_class	base	gama 1-4 · RobustScaler	Nivel de gama
main_is_van	derivada	binaria 0/1	Uso profesional

Feature	Origen	Codificación	Para qué sirve
has_telemetry	derivada	binaria 0/1	Cliente conectado
finance_leasing_status	base	one-hot (4)	Relación con la financiera
main_engine_concept	base tratada	one-hot (5)	Afinidad eléctrica

- **Excluidas por sensibles o sin valor analítico:** identificadores, variables de alta cardinalidad (*model_series*, *vehicle_type*, resumidas en la gama comercial), textos multivalor y el género inferido, para evitar sesgos.
- **Excluidas por redundancia (multicolinealidad):** *itvs_passed_count* depende directamente de la antigüedad del vehículo (correlación 0,86) y *currently_connected_vehicles* ya forma parte de *digital_engagement_index* (0,96).
- **Conservadas solo para perfilar:** *urban_density_classification* (varía muy poco entre zonas), el país y la telemetría en bruto.

E. Pipeline de transformación

Para garantizar la reproducibilidad y evitar fugas de datos, todo el proceso se encapsuló en un *Pipeline* de Scikit-Learn: tratamiento de nulos, agregación a cliente, features derivadas y un *ColumnTransformer* que prepara las 11 variables (18 columnas tras la codificación):

- **Imputación:** mediana en las numéricas, robusta ante valores atípicos.
- **Transformación logarítmica (log1p):** en las variables con cola larga (poder adquisitivo, visitas al taller e índice digital), para que las cuentas de flota no dominen las distancias.
- **Escalado robusto (RobustScaler):** centra cada variable en su mediana y la escala por su rango intercuartílico, de modo que los valores extremos detectados en el reto 1 no deforman la escala del resto de clientes.
- **Codificación de categóricas:** ordinal para la edad (6 tramos) y la gama del vehículo (1 a 4); one-hot para la financiación y la motorización; las binarias se mantienen en 0/1 para que no dominen la distancia.