RETO 2 - MERCEDES BENZ

Grupo: Cibercolegas
Nombres: Noa Ramos Ruiz, Javier Romeo Enríquez de Salamanca, Mario Cáceres Morales, Noelia Sánchez Vilchez

A. Tratamiento de Nulos y Limpieza de Datos

A partir de las conclusiones del análisis exploratorio (EDA), se eliminaron aquellas columnas que no aportan valor analítico directo para la segmentación de clientes (como el índice exportado, identificadores únicos, modas concatenadas, contadores puramente técnicos y variables de telemetría en bruto con más del 60% de valores faltantes).

- **Deducción lógica de variables clave:** En lugar de eliminar filas o realizar imputaciones aleatorias, se implementaron reglas de negocio y cascadas de decisión para rescatar valores nulos en `model_class`, `engine_concept` y `fuel_type` a partir de los nombres comerciales de los vehículos y sus series, logrando precisiones superiores al 95%.
- **Variables socioeconómicas y geográficas:** Los valores ausentes en las métricas de poder adquisitivo y población por zona se imputaron utilizando la mediana específica de cada país de mercado (Suiza o Austria), marcando dichos registros con un indicador de imputación (`socio_imputed`).
- **Telemetría:** Las métricas de telemética (velocidades, distancias, consumos) se excluyeron del entrenamiento algorítmico debido a su alta tasa de nulos estructurales, transformándose en un indicador binario de conectividad (`has_telemetry`).

B. Agregación a una Fila por Cliente

Para aplicar técnicas de aprendizaje no supervisado enfocadas en la persona (estrategias de marketing, ofertas de vehículos y planes de mantenimiento), se estructuró la tabla a nivel de cliente único (`client_id`):

- **Vehículo Principal:** Para cada cliente se identifica su vehículo principal, definido como el vehículo actual matriculado más recientemente (o el más reciente de su historial en caso de no disponer de uno activo).
- **Consolidación del Historial:** Se añadieron métricas agregadas del historial completo de la cuenta, tales como el número total de vehículos distintos asociados (`n_vehicles_history`), las visitas acumuladas al taller en garantía (`workshop_visits_total`), un indicador de pertenencia a flotas o empresas (`is_b2b`) y el estado de conectividad.

C. Construcción de Features Derivadas

Se diseñaron variables derivadas orientadas a capturar el comportamiento real del cliente y su relación con la marca:

1. **`main_vehicle_age_years` (Antigüedad del vehículo principal):** Mide los años transcurridos desde la primera matriculación del vehículo principal respecto a la fecha de referencia. Es la variable clave para detectar la ventana comercial óptima de renovación.

2. **`tenure_years` (Antigüedad como cliente):** Calcula los años que el usuario lleva vinculado a Mercedes-Benz a partir de los meses transcurridos desde su primera conexión.

3. **`itvs_passed_count` (Inspecciones técnicas superadas):** Estima el número de revisiones técnicas obligatorias que ha superado el vehículo según la normativa específica del país de mercado (Suiza o Austria) y su antigüedad.

4. **`warranty_visit_frequency` (Frecuencia de visitas en garantía):** Relaciona el total de visitas al taller en periodo de garantía con el volumen histórico de vehículos del cliente, identificando perfiles con necesidades de posventa intensivas.

5. **`has_telemetry` (Indicador de cliente conectado):** Variable binaria (0 o 1) que detecta si el vehículo transmite datos activos de telemática, separando al usuario digital del tradicional.

6. **`urban_density_classification` (Densidad demográfica del hogar):** Relaciona la población total y el número de hogares del código postal para contextualizar el entorno del usuario.

7. **`digital_engagement_index` (Índice de conectividad multicanal):** Pondera el volumen de vehículos actualmente conectados junto con la predisposición del cliente a recibir comunicaciones digitales.

8. **`main_is_van` (Indicador de vehículo comercial):** Variable binaria que aísla de forma limpia el uso profesional o de furgoneta (Sprinter, Vito, Citan) frente al turismo particular.

D. Selección Justificada de Features para el Modelo

De entre todo el abanico de variables, se seleccionaron aquellas que cumplen con los criterios de alto valor comercial, baja tasa de nulos y nula redundancia:

- **Variables de Relación:** `currently_connected_vehicles`, `n_vehicles_history`, `tenure_years`, `is_b2b`, `finance_active`.

- **Variables de Posventa y Uso:** `warranty_visit_frequency`, `has_telemetry`.
- **Variables del Vehículo:** `main_vehicle_age_years`, `main_segment_tier`, `main_electrification`, `main_is_van`.
- **Variables Demográficas:** `purchasing_power_per_household_eur`, `age_range`.

Se excluyeron deliberadamente identificadores únicos, variables de alta cardinalidad no resumidas, textos multivalor y atributos inferidos sensibles (como el género derivado) para evitar sesgos algorítmicos.

Asimismo, se ha tenido en cuenta que no existan correlaciones positivas o negativas excesivas (multicolinealidad) entre las variables de entrada para no distorsionar el cálculo de distancias del algoritmo K-Means. Como ejemplo de ello, se descartaron de forma justificada variables como model_series o vehicle_type, cuya alta correlación y redundancia directa ya quedaba resumida de forma óptima a través de la gama comercial (model_class).

E. Pipeline de Transformación

Para garantizar la reproducibilidad y evitar fugas de datos (data leakage), todo el preprocesamiento se encapsuló en un `Pipeline` de Scikit-Learn mediante un `ColumnTransformer`:

- **Imputación:** Se aplicó imputación por la mediana en variables numéricas para conferir robustez ante valores atípicos, y por la moda en variables binarias.
- **Transformación Logarítmica (`log1p`):** Aplicada a variables monetarias y de conteo con asimetría pronunciada hacia la derecha (como el poder adquisitivo o el número de vehículos), evitando que cuentas de flotas dominen desproporcionadamente las distancias euclidianas.
- **Escalado Estándar (`StandardScaler`):** Imprescindible para algoritmos basados en distancias como K-Means, asegurando que todas las variables contribuyan con el mismo peso en el espacio vectorial.