RETO 3 - MERCEDES BENZ

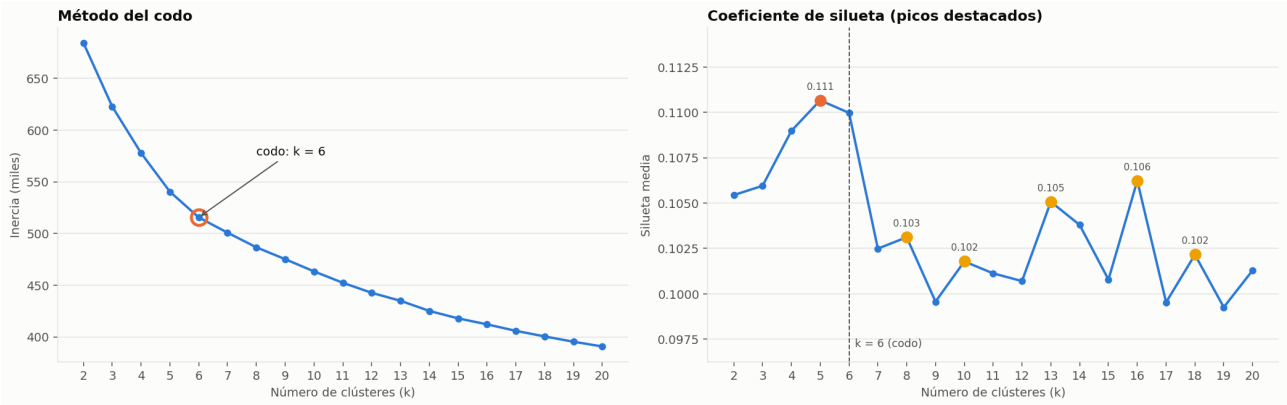
Grupo: Cibercolegas
Nombres: Noa Ramos Ruiz, Javier Romeo Enríquez de Salamanca, Mario Cáceres Morales, Noelia Sánchez Vilchez

A. Planteamiento

El modelo K-Means se entrenó sobre la matriz preparada en el reto 2: **173.456 clientes** (una fila por cliente) y **18 columnas** codificadas y escaladas. Como K-Means necesita conocer de antemano el número de grupos (k), se entrenó un modelo para cada valor entre **k = 2 y k = 20**, siempre con **random_state=42** (resultados reproducibles) y **n_init=10** (10 arranques distintos, conservando el mejor). Cada modelo se evaluó con:

- **Inercia (método del codo):** compactación de los grupos. El codo se localizó de forma objetiva con el método *kneedle*.
- **Coeficiente de silueta:** si cada cliente está más cerca de su grupo que del vecino. Se calculó sobre 3 muestras aleatorias de 20.000 clientes (con todos serían unos 30.000 millones de distancias) y se promedió.
- **Davies-Bouldin y Calinski-Harabasz:** métricas de apoyo sobre la separación entre grupos.
- **Tamaño del segmento más pequeño:** criterio de negocio, ya que un segmento diminuto no justifica una campaña propia.

B. Resultados de las métricas



k	Inercia	Silueta	Davies-Bouldin	Segmento menor	Segmento mayor
4	577.786	0,1090	2,276	21,0 %	29,4 %
5	540.424	0,1107	2,031	18,7 %	22,5 %
6	515.542	0,1100	1,963	12,4 %	19,3 %
7	500.786	0,1025	2,107	10,7 %	17,8 %
8	486.648	0,1031	2,168	8,4 %	17,4 %

- **Codo:** la inercia cae con fuerza hasta k = 6 y a partir de ahí la curva se aplana. El método kneedle sitúa el codo en **k = 6**.
- **Silueta:** el máximo está en **k = 5 (0,1107)**, prácticamente empatado con **k = 6 (0,1100)**; la diferencia es inferior a una milésima. A partir de k = 7 la silueta cae y no vuelve a alcanzar esos valores.
- **Davies-Bouldin:** alcanza su mejor valor de todo el rango en **k = 6 (1,963)**. Calinski-Harabasz baja de forma continua al aumentar k, por lo que no discrimina por sí solo.
- **Tamaño de los segmentos:** hasta k = 6 el segmento más pequeño supera el 12 % de los clientes; desde k = 8 baja del 10 % y desde k = 14 aparecen segmentos por debajo del 5 %.

C. Selección y justificación del número óptimo de clusters: k = 6

- **Justificación técnica:** k = 6 es el único valor en el que coinciden varias señales. Es el codo de la curva de inercia, tiene el mejor índice Davies-Bouldin del rango y su silueta está a menos de una milésima del máximo, una diferencia sin relevancia práctica.

- **Justificación de negocio:** seis segmentos son gestionables por un equipo de marketing con estrategias diferenciadas y todos son suficientemente grandes. Además, al pasar de 5 a 6 aparece un grupo muy accionable: clientes con el vehículo más antiguo (mediana de unos 9 años), casi sin financiación activa y prácticamente sin vehículos electrificados. Con k = 5 estos clientes estaban repartidos entre cuatro segmentos; con k = 6 forman el público natural de las campañas de renovación.
- **Por qué no más clusters:** por encima de k = 8 la base se fragmenta en grupos pequeños que se diferencian por matices y no justifican campañas distintas: más segmentos no significan mejor segmentación.

D. Modelo final y distribución de clientes

El modelo final se entrenó con **k = 6** y los mismos parámetros (random_state=42, n_init=10). Cada cliente recibe su etiqueta de clúster y la tabla resultante se guarda para el reto 4. Los seis segmentos están equilibrados:

Clúster	0	1	2	3	4	5	Total
Clientes	29.388	26.245	31.980	30.809	21.510	33.524	173.456
% del total	16,9 %	15,1 %	18,4 %	17,8 %	12,4 %	19,3 %	100 %

E. Robustez del modelo

- **Cohesión de cada clúster (gráfico de silueta por clúster):** todos los clústeres tienen silueta media positiva y solo un 5,5 % de los clientes queda en la frontera entre dos segmentos. El clúster 3 es el más cohesionado (silueta 0,144, sin clientes en la frontera) y el clúster 1 el más difuso (0,063, con un 17 % en la frontera), por lo que conviene presentarlo como un perfil de bordes menos nítidos.
- **Estabilidad frente a la inicialización:** entrenado con otras cinco semillas, el modelo obtiene prácticamente la misma segmentación (ARI entre 0,990 y 0,996, donde 1 significa segmentaciones idénticas) y la misma inercia. Los segmentos no dependen del azar del punto de partida; la semilla fija solo garantiza que la numeración de los clústeres sea siempre la misma.
- **Interpretación de la silueta:** los valores son modestos en todo el rango (0,10-0,11), lo habitual con datos reales de clientes, que forman un continuo de perfiles más que grupos aislados. Por eso la silueta se usa para comparar valores de k entre sí y los segmentos se interpretan como perfiles tipo útiles para orientar acciones comerciales.