# RETO 1 - MERCEDES BENZ

Grupo: Cibercolegas
Nombres: Noa Ramos Ruiz, Javier Romeo Enríquez de Salamanca, Mario Cáceres Morales, Noelia Sánchez Vilchez

## Principales características de los clientes

- Los clientes corresponden a un mercado **alpino** y **maduro**, concentrados principalmente en **Suiza** (alrededor del 66%) y **Austria** (34%), con un poder adquisitivo por hogar notablemente elevado cuya mediana ronda los **100.000 euros**, siendo significativamente superior en el caso suizo.

- El perfil demográfico muestra una clara inclinación hacia una **edad media-alta**, donde el 61% de los clientes supera los 45 años y el segmento menor de 25 años es residual (menos del 5%). De acuerdo con el género inferido, el 78% de los usuarios con registro conocido son **hombres**, mientras que un 17% no presenta dato (No se ha inferido un género a partir de sus otras características).

- En cuanto a la relación con la marca, se observa una vinculación reciente pero estable, con una mediana de **tres años** como cliente conectado y un máximo registrado de diez. La gran mayoría (81%) dispone de un **único vehículo conectado**. Un 10% no cuenta actualmente con un vehículo activo, lo que señala un riesgo potencial de fuga, mientras que una minoría concentrada de clientes multivehículo o **gestores de flota** acumula **gran parte** de los automóviles. La presencia de cuentas B2B es marginal, representando solo un 0,6%.

- Respecto a la gama de productos, destacan las categorías **SUV** y las **familias compactas y medias**, lideradas por modelos como el GLC, la Clase C, la Clase A y las variantes GLA/GLB. El segmento de **furgonetas** (V-Class, Vito y Sprinter) conforma un **nicho de relevancia**. La penetración de vehículos **electrificados** (híbridos enchufables y 100% eléctricos) alcanza ya al **22%** de los vehículos principales, situándose en uno de cada cinco automóviles.

- En el apartado financiero, un **29%** de la base de clientes ha utilizado en alguna ocasión las fórmulas de **leasing o financiación** oficial de Mercedes-Benz (con un 26% mantenido en contrato activo), mientras que el porcentaje restante adquiere los vehículos al contado o mediante entidades externas.

- La receptividad ante las comunicaciones de marketing es excepcionalmente alta en todos los canales: el **98%** consiente el contacto por **correo** electrónico, el **86%** por **teléfono** y el **85%** por correo **postal**, con un **81%** aceptando los **tres canales** de forma simultánea. Debido a esta aceptación generalizada, el consentimiento comercial no constituye una variable discriminante para la segmentación.

- Por último, en cuanto al nivel de conectividad, solo la **mitad** de los clientes dispone de algún vehículo configurado con envío activo de **telemetría** de conducción.

## Problemas de calidad detectados y soluciones aplicadas

- En primer lugar, se identificó un problema de **granularidad mixta** debido a la coexistencia de registros por cliente y por vehículo. Esto se resolvió realizando una agregación a nivel de cliente, identificando su vehículo principal y creando variables consolidadas sobre su historial.

- En segundo lugar, las variables relativas al bloque de **telemetría** presentaban un 60% de valores nulos. Para no penalizar el modelado, estas métricas se excluyeron del entrenamiento del algoritmo de clustering y se reservaron de forma exclusiva para el perfilado posterior de los grupos.

- En tercer lugar, la **variable de motorización** contaba con un 44% de valores ausentes. Esta información se logró inferir analizando el nombre comercial de cada modelo, alcanzando un acierto comprobado de aproximadamente el 95% sobre los registros que sí contenían el dato original.

- En cuarto lugar, se detectó un 1,1% de nulos en la columna de **clase de modelo** (model_class), los cuales se recuperaron casi en su totalidad (3.368 de los 3.369 registros con falta) imputando el valor directamente a partir del **tipo de vehículo** (vehicle_type).

- En quinto lugar, se detectaron inconsistencias como **fechas de matriculación implausibles** (por ejemplo, registros del año 1987) y zonas geográficas con población igual a cero por falta de datos. Estos registros erróneos se transformaron a **valores nulos** y posteriormente se imputaron utilizando la **mediana** del resto de la muestra.

- En sexto lugar, se procedió a la exclusión limpia de aquellas variables sin valor analítico directo, entre las que se incluyen **índices** internos, **identificadores** únicos, **códigos postales**, **modas** con valores múltiples y **contadores** puramente técnicos.

- Por último, se decidió dejar fuera del modelo **variables sensibles** inferidas como el género derivado (gender_derived), con el objetivo de evitar que el algoritmo genere segmentos basados en atributos que el cliente no ha declarado explícitamente.