RETO 1 - MERCEDES BENZ

Grupo: Cibercolegas
Nombres: Noa Ramos Ruiz, Javier Romeo Enríquez de Salamanca, Mario Cáceres Morales, Noelia Sánchez Vilchez

A. Principales características de los clientes

La base contiene **302.850 relaciones cliente-vehículo** de **173.456 clientes** y 244.519 vehículos, descritas por 39 columnas.

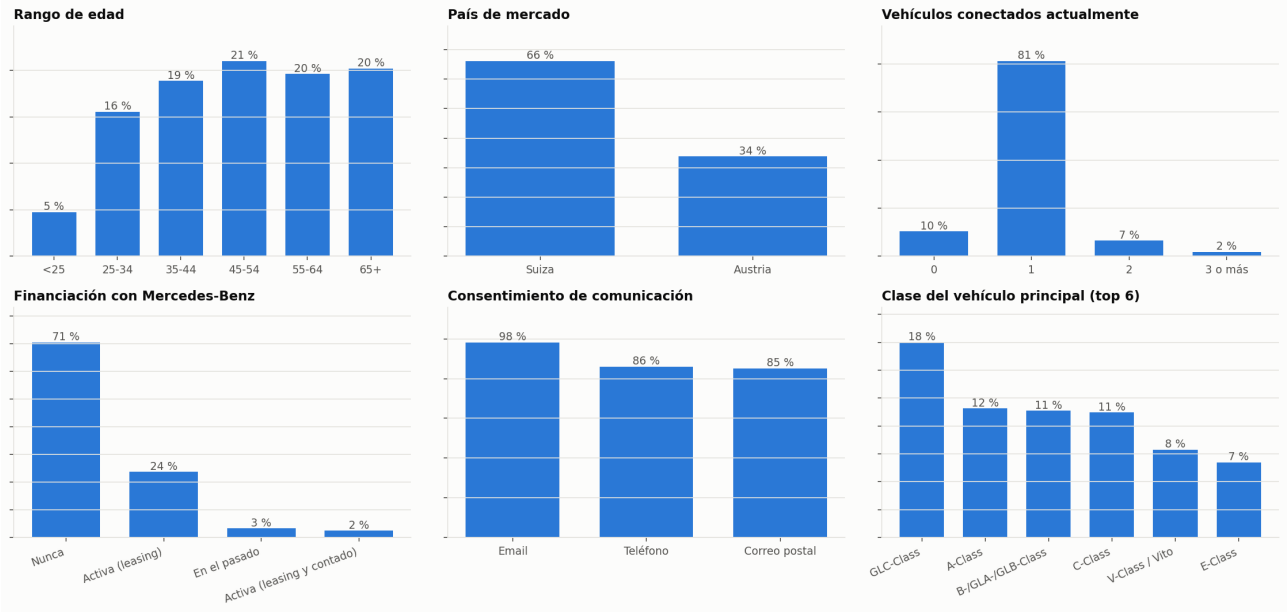


Figura 1. Perfil de los clientes (porcentaje sobre el total de clientes).

- **Mercado alpino y maduro:** los clientes se concentran en **Suiza** (66 %) y **Austria** (34 %), con un poder adquisitivo por hogar notablemente elevado cuya mediana ronda los **104.000 euros**, significativamente superior en el caso suizo.
- **Edad media-alta:** el 61 % de los clientes tiene 45 años o más y el segmento menor de 25 años es residual (4,7 %). Según el género inferido, el 78 % de los clientes con dato son hombres, y un 17 % no tiene género inferido.
- **Relación con la marca:** vinculación reciente pero estable, con una mediana de **3 años** como cliente conectado. El 81 % dispone de un **único vehículo conectado** y un 10 % no tiene ninguno activo, lo que señala un riesgo potencial de fuga. Una minoría de clientes multivehículo o gestores de flota acumula muchos vehículos; las cuentas B2B son marginales (0,6 %).
- **Gama de productos:** destacan los SUV y las familias compacta y media (GLC, Clase A, GLA/GLB, Clase C), con las furgonetas (V-Class, Vito, Sprinter) como nicho relevante. Los vehículos electrificados (híbridos enchufables y eléctricos) alcanzan ya el **22 %** de los vehículos principales, uno de cada cinco.
- **Financiación:** el 29 % ha utilizado alguna vez la financiación oficial de Mercedes-Benz (el 26 % con contrato activo); el resto compra al contado o con entidades externas.
- **Comunicación:** la receptividad es muy alta: el 98 % acepta el email, el 86 % el teléfono y el 85 % el correo postal (81 % los tres). Por eso el consentimiento no es una variable útil para diferenciar clientes.
- **Conectividad:** en torno a la mitad de los clientes tiene algún vehículo que envía datos de conducción (telemetría).

B. Problemas de calidad detectados y soluciones aplicadas

De las 39 columnas, 23 tienen valores nulos. Se distinguen tres bloques con causas distintas: la **telemetría** (alrededor del 60 %), la **motorización** (44 % en *engine_concept*) y los datos de la **zona** (6,3 %), que faltan a la vez para un mismo código postal.

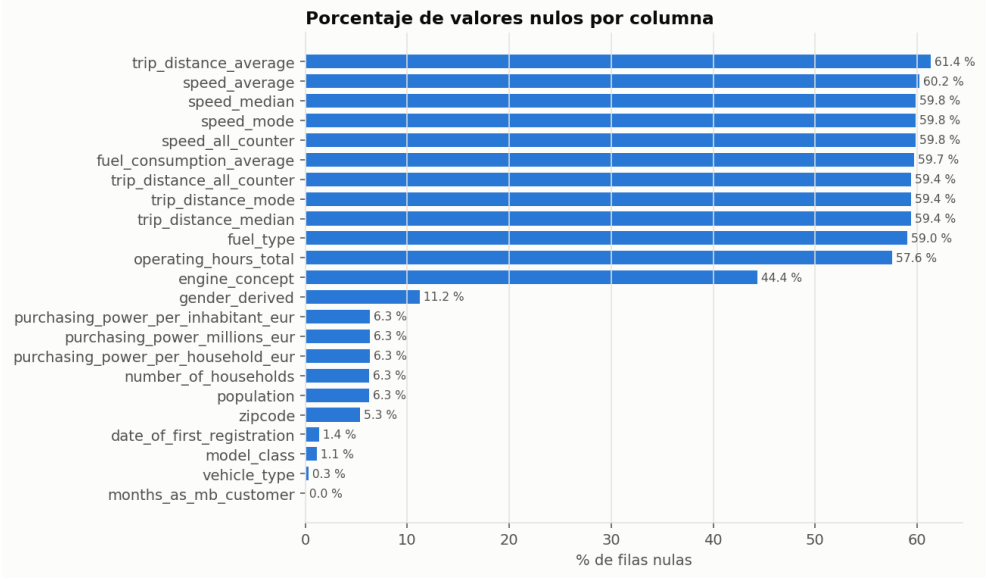


Figura 2. Porcentaje de valores nulos por columna.

Problema	**Solución aplicada**
Granularidad mixta: cada fila es una relación cliente-vehículo	Agregación a una fila por cliente, con su vehículo principal y variables consolidadas de su historial.
Telemetría con alrededor del 60 % de nulos (el coche no envía datos)	Excluida del entrenamiento del clustering; se resume en un indicador de cliente conectado y se usa para perfilar.
Motorización (*engine_concept*) con un 44 % de nulos	Se infiere del nombre comercial del modelo (acierto comprobado de alrededor del 95 % sobre los datos conocidos); los casos sin evidencia quedan como desconocidos en lugar de suponer combustión.
Clase de modelo (*model_class*) con un 1,1 % de nulos	Recuperada casi por completo (3.368 de 3.369 registros) a partir del tipo de vehículo (*vehicle_type*).
Fechas de matriculación implausibles (1987) y zonas con población igual a cero	Se transforman en nulos y se imputan en el reto 2: la fecha con la mediana de su serie de modelo y los datos de zona con la mediana de su país.
Columnas sin valor analítico	Exclusión de índices internos, identificadores, códigos postales, modas con varios valores y contadores técnicos.
Variables sensibles inferidas (*gender_derived*)	Fuera del modelo, para no segmentar por un atributo que el cliente no ha declarado.